

STUFE 1: Intake & Hygiene – Checkliste

Zweck: Klassifizierung, PII-Bereinigung, Datenpass erstellen
Wichtig: Stufe 1 trifft **KEINE** finale Rechts- oder Use-Case-Freigabe!

Allgemeine Angaben

Feld	Eintrag
Datum	
Prüfer:in	
Quelle/Domain	
Lieferungs-ID	

S1.1 QUELLE & ZUGRIFF

S1-01: Wie wurden die Daten erhoben?

Ankreuzen	Wert	Beschreibung	Pool
☐	Eigene Daten	Eigene Redaktion, intern erzeugte Inhalte	→ Z4 SAFE 
☐	Kooperation	Partnerlieferung, autorisierte API/Feeds	→ Z4 SAFE 
☐	Plattform	YouTube, Social Media, Plattform-APIs	→ Z2 PLATFORM 
☐	Unkooperativ	Scraping trotz Verbot → BLOCK.UNCOOP	→ Z0 BLOCK 
☐	Unbekannt	Herkunft nicht belegbar	→ Z5 UNKLAR 

S1-02: Kooperationsnachweis? (nicht bei Eigene Daten)

Ankreuzen	Wert	Wirkung
☐	Ja	Vertrag überschreibt Lizenz/ToS/TDM in Stufe 2
☐	Nein	Stufe 2 prüft alle Rechtefragen
☐	Unklar	Stufe 2 prüft alle Rechtefragen

 Bei Kooperationsnachweis werden in Stufe 2 viele Fragen übersprungen

S1.2 KOMPONENTEN-CHECK

S1-03: Welche Komponenten enthält der Datensatz? (Mehrfachauswahl)

Basis-Komponenten:

☐	Komponente	Beschreibung
--------------------------	------------	--------------

☐	FACTS	Strukturierte Fakten (Titel, Autor, Jahr, URL)
☐	TEXT	Schöpferische Texte (Beschreibung, Abstract, Fließtext)
☐	MEDIA	Bilder/Videos (Thumbnails, Previews)

Derivat-Komponenten: (erben alle Tags der Basis)

☐	Komponente	Beschreibung
☐	COMPENDIUM_TEXT	Zusammenfassungen
☐	QA_PAIRS	Frage-Antwort-Paare
☐	INDEX	Suchindex/Embeddings
☐	MODEL_WEIGHTS	Trainierte Modellgewichte

S1-04: Umgang mit Mediendateien? (nur wenn MEDIA vorhanden)

Ankreuzen	Wert	Wirkung
☐	Nur verlinken	→ REQ.LINK_ONLY (Medien nicht kopieren)
☐	Kopiert	Rechte müssen in Stufe 2 geklärt werden

S1.3 DATENSCHUTZ / PII-CHECK

S1-05: Personenbezogene Daten (PII) im Datensatz?

Ankreuzen	Wert	Wirkung
☐	Keine PII	→ Weiter
☐	PII möglich	→ Weiter, aber prüfen
☐	Hohes PII-Risiko	→ S1-06 beantworten!

S1-06: PII erfolgreich minimiert? (nur bei hohem PII-Risiko)

Ankreuzen	Wert	Wirkung
☐	Ja, mitigiert	PII entfernt/anonymisiert → Weiter
☐	Nein	→ BLOCK.PII_QUARANTINE → Z1 QUARANTÄNE 🚫



BLOCKER-CHECK

Bedingung	Pool	Aktion
Unkooperativ gewählt	Z0 BLOCK 🚫	STOPP! Keine weitere Verarbeitung
Hohes PII-Risiko + Nein bei S1-06	Z1 QUARANTÄNE 🚫	QUARANTÄNE! PII-Bereinigung nötig

Unbekannt gewählt	Z5 UNKLAR ?	Weiter, Klärung in Stufe 2
-------------------	-------------	----------------------------

Blocker? ☐ Nein → Weiter zu Datenpass ☐ Ja → Stopp/Quarantäne

DATENPASS (Output Stufe 1)

Feld	Wert
Herkunft	☐ Eigene ☐ Kooperation ☐ Plattform ☐ Unkooperativ ☐ Unbekannt
Kooperationsnachweis	☐ Ja ☐ Nein ☐ Unklar ☐ n/a
Komponenten	☐ FACTS ☐ TEXT ☐ MEDIA ☐ Derivate: _____
Media-Speicherung	☐ Nur verlinken ☐ Kopiert ☐ n/a
PII-Status	☐ Keine ☐ Möglich ☐ Hoch
PII mitigiert	☐ Ja ☐ Nein ☐ n/a

Pool-Zuordnung:

Ankreuzen	Pool	Bedingung
☐	Z0 BLOCK 🛑	Unkooperativ
☐	Z1 QUARANTÄNE 🛑	PII hoch + nicht mitigiert
☐	Z2 PLATFORM 🟡	Plattform-Daten
☐	Z4 SAFE ✅	Eigene/Kooperation ohne Blocker
☐	Z5 UNKLAR ?	Herkunft unbekannt

Tags aus Stufe 1

Tag	Gesetzt?	Wirkung
BLOCK.UNCOOP	☐	Alle Use Cases gesperrt
BLOCK.PII_QUARANTINE	☐	Alle Use Cases gesperrt
REQ.LINK_ONLY	☐	Medien nur verlinken

WEITER ZU STUFE 2?

Checkliste:

☐	Voraussetzung
☐	Datenpass vollständig

☐	Kein BLOCK.UNCOOP (sonst: Z0 → Ende)
☐	Kein BLOCK.PII_QUARANTINE (sonst: Z1 → Klärung)

 **Bei Kooperationsnachweis:** Lizenz-, ToS-, TDM- und DB-Fragen werden übersprungen

Unterschrift: _____ **Datum:** _____